



Budapesti Műszaki és Gazdaságtudományi Egyetem
Villamosmérnöki és Informatikai Kar
Szélessávú Hírközlés és Villamosságtan Tanszék

Önálló laboratórium 2 dolgozat

Modell-redukció alkalmazása az elektromágneses térszámításban

Szilágyi Gábor

Konzulens: Dr. Bilicz Sándor

Budapest, 2022. október 23.

Tartalomjegyzék

1. Bevezetés	1
1.1. Felhasználási területek	1
1.2. Alkalmazás az elektromágneses térszámításban	1
2. A POD-ról részletesebben	2
2.1. A felbontás egyenletei	2
3. L^AT_EX Próba	3

1. Bevezetés

A POD, vagyis a Proper Orthogonal Decomposition, egy modellredukciós eljárás, ami egy adott adathalmaz reprezentálásához optimális bázist keres meg. Az eljárás által meghatározott Ψ bázisban a bázisvektoroknak az a tulajdonsága, hogy a lehető legkevesebb bázisvektorral leírható az adathalmaz információtartalmának vagy energiájának lehető legnagyobb része. Ezt felhasználva a Ψ csonkolásával egy közelítő bázist lehet előállítani (Ψ'), ami lényegesen kisebb rendű, mint Ψ , mégis kis hibával reprezentálható benne az eredeti adathalmaz. Természetesen minél több bázisvektort hagyunk meg Ψ' -ben, annál jobban csökken a modell-redukcióból származó hiba, de a csonkolás mértékét az adott alkalmazáshoz mérten előírhatjuk. A POD egy másik előnyös tulajdonsága, hogy a gyakorlati esetek nagy részében a sorbarendezt ψ_n bázisvektorokra eső energiatartalom rohamosan csökken, ezért sokszor nagyságrendekkel kisebb dimenziószámú bázissal is jól leírható az adathalmaz, mint az eredeti esetben.

1.1. Felhasználási területek

A POD eljárást számos tudományterületen sikeresen alkalmazták már, különböző területeken különböző néven szokták emlegetni gyakorlatilag ugyanezt az eljárást. Statisztikában főként Principal Component Analysis (PCA) néven fordul elő és nagy adathalmazok információtartalmának kinyerésére használják.

Ezeknél a problémáknál az okozza általában a fő gondot, hogy a szimulált rendszer szabadsági fokainak száma nagyon nagy, emiatt egy-egy szimuláció nagyon sok ideig tart, pontatlanabb diszkretizált modell pedig fals eredményekre vezet. Nagy adathalmazok redukálása esetén pedig lényeges, kezelhető méretű információtartalom kinyerésére szolgál. Lényeges felhasználási területek például: turbulens áramlások szimulációja; statisztikában és más területeken az adathalmazok redukálása; szabályozástechnikában a szuboptimális, de gyorsan számítható beavatkozás; nemlineáris elektromágneses problémák (pl. motorok) szimulációja.

1.2. Alkalmazás az elektromágneses térszámításban

Az EM térszámításban többféle kontextusban is hasznos lehet a POD a futási idő vagy a memóriafelhasználás jelentős csökkentésére. Az egyik megközelítésben egy végeelem modellben zajló tranziens folyamat lefolyására kaphatunk számítás szempontjából olcsó, közelítő megoldást. Ehhez először a teljes kérdéses időintervallum első töredék részére egy teljes értékű szimulációt futtatunk, amely viszonylag sok számítást igényel. Ennek a rövid részmegoldásnak az eredményei szolgálnak a POD bemenetüli. A POD ezek alapján meghatározza a rendszer dinamikájában megjelenő struktúrákat, majd csak a lényeges összetevőkre szorítkozva egy lecsökkentett szabadsági fokú rendszert szimulálunk tovább a hátralévő időben, ami már időlépé-

senként sokkal kevesebb számítást igényel. Ez a módszer az 1980-as években született turbulens áramlások szimulációja kapcsán [2], amellyel a Method of Snapshots néven találkozhatunk.

A fent vázolt, tranziens szimulációban történő alkalmazáson kívül más módokon is használható lehet a POD a térszámítási problémákban, de a dolgozatomban elsősorban ezzel a megközelítéssel foglalkozom.

2. A POD-ról részletesebben

A bevezetésben említettem, hogy az adathalmaz energiájának vagy információtartalmának szempontjából optimális a Ψ bázis, de ez pontosításra szorul.

2.1. A felbontás egyenletei

A redukálható adathalmaz méreteitől függően különböző számítási módok optimálisak a POD redukált bázisának előállításához. Az eredeti adathalmazt egy mátrixba rendezzük úgy, hogy az egyes mintákhoz tartozó adatok vektorai ($\mathbf{x}_i \in \mathbb{C}^n$, $i \in \{1, \dots, k\}$) a mátrix oszlopvektorai legyenek. Az így kapott mátrix (\mathbf{S}) a snapshotmátrix vagy mintamátrix:

$$\mathbf{S} = [\mathbf{x}_1 \ \mathbf{x}_2 \ \mathbf{x}_3 \ \dots \ \mathbf{x}_k] \quad (1)$$

Az adott alkalmazástól függ, hogy \mathbf{S} -nek melyik mérete olyan nagy, hogy az gondot jelentsen. Az 1.2. részben vázolt nagy szabadsági fokú szimulációknál az okozza a gondot, hogy az egy időlépéshez tartozó \mathbf{x}_i dimenziószáma – vagyis n – nagy, könnyen milliós nagyságrendű, miközben egy jó redukált bázis előállításához, $k \ll n$ db. \mathbf{x}_i minta elég a dinamikus rendszerből. Ebben az esetben jól használható az \mathbf{S} sajátfelbontása (SVD-je):

$$\mathbf{S} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^H \quad (2)$$

Itt érdemes megállni és értelmezni a felbontásban szereplő mátrixokat és azok jelentését a modellezett rendszerrel kapcsolatban. A 2. egyenletben $\mathbf{U} \in \mathbb{C}^{n \times k}$ lesz a teljes Ψ bázis vektorait (\mathbf{u}_i , $i \in \{1, \dots, k\}$), mint oszlopvektorokat tartalmazó unitér mátrix, tehát az oszlopai egységvektorok. A $\mathbf{\Sigma} \in \mathbb{R}^{m \times m}$ ($m = \min\{n, k\} = k$) egy pozitív definit diagonálmátrix, aminek az i -edik diagonálelemei, σ_i az \mathbf{u}_i -hez tartozó együttható, ami azt fejezi ki, hogy az adott bázisvektor mennyire fontos, mennyire járul hozzá általában a rendszer állapotához, más szóval a rendszer energiájának vagy információtartalmának mekkora része írható le az adott bázisvektorral. A $\mathbf{\Sigma}$ olyan felépítésű az SVD miatt, hogy a diagonálelemek csökkenő sorrendben szerepelnek az átlóban bal fentről jobbra lefelé haladva. A $\mathbf{U} \mathbf{\Sigma} \in \mathbb{C}^{n \times m}$ szorzat tehát már az eredeti adatokhoz skálázott bázisvektorok mátrixának tekinthető, amelyben fontosság szerint csökkenő sorrendben szerepelnek egymás után a bázisvektorok. Tömören összefoglalva a \mathbf{V}^H mátrix a skálázott bázisvektorokhoz tartozó együtthatók mátrixa. A \mathbf{V}^H mátrix az i -edik \mathbf{v}_i oszlopában tartalmazza az \mathbf{x}_i mintavektor előállításához szükséges együtthatókat, amelyek a $\mathbf{U} \mathbf{\Sigma}$ szorzat oszlopait súlyozzák:

$$\mathbf{x}_i = \mathbf{U} \mathbf{\Sigma} \mathbf{v}_i \quad (3)$$

Más szemszögből megközelítve a \mathbf{V}^H értelmezését, $v_{j,i}$, tehát \mathbf{V}^H j -edik sorának i -edik eleme (\mathbf{v}_i j -edik eleme) jelenti $\mathbf{u}_j \sigma_j$ hozzájárulását vagy súlyát \mathbf{x}_i -hez.

Az ellenkező esetben, amikor k nagy és emiatt $m = \min\{n, k\} = n$, már számításigény szempontjából nem optimális \mathbf{S} szinguláris érték szerinti felbontásának direkt kiszámolása, mert ez az immár $k \times k$ méretű \mathbf{V}^H mátrix kiszámolásával jár, ami a redukált modell létrehozása szempontjából lényegtelen. Ebben az esetben érdekesebb kiszámítani az adathalmaz

kovarianciamátrixát, a $\mathbf{C} \in \mathbb{C}^{n \times n}$ mátrixot. Azért jutunk ezzel előrébb, mert a 4. egyenletben látható módon az \mathbf{U} mátrixot megkaphatjuk a \mathbf{C} sajátfelbontásából is. Mivel \mathbf{C} szimmetrikus, ezért pozitív definit, emiatt mindig létezik sajátfelbontása.

$$\begin{aligned}\mathbf{C} &= \mathbf{S}\mathbf{S}^H \\ &= \mathbf{U}\mathbf{\Sigma}\mathbf{V}^H\mathbf{V}\mathbf{\Sigma}\mathbf{U}^H \\ &= \mathbf{U}\mathbf{\Sigma}^2\mathbf{U}^H\end{aligned}\tag{4}$$

Itt \mathbf{S} a snapshot-mátrix, \mathbf{U} oszlopai az új bázisvektorok, $\mathbf{\Sigma}$ tartalmazza a bázisvektorok információtartalmát jellemző szinguláris értékeket a főátlójában, \mathbf{V}^H sorai az egyes bázisvektorok időfüggő együtthatói, \mathbf{C} pedig az \mathbf{x}_i mintavektorokból álló adathalmaz kovarianciamátrixa.

3. L^AT_EX Próba

Lorem ipsum [1].

$$\mathbf{X} = \mathbf{V}\mathbf{\Sigma}\mathbf{U}^*\tag{5}$$

Hivatkozások

- [1] Francisco Chinesta, Roland Keunings, Adrien Leygue. *The Proper Generalized Decomposition for Advanced Numerical Simulations*. Springer Cham, 2014. DOI: 10.1007/978-3-319-02865-1.
- [2] Lawrence Sirovich. Turbulence and the dynamics of coherent structures. I-III. *Quarterly of Applied Mathematics*, 45:561–590, 1987.